Statystyka w sztucznej inteligencji i analizie danych 2024/25

Raport: Modele regresji

Regresja liniowa i interakcje

Zadanie 1

Dostępne są zbiory danych:

1.1 Real Estate Valuation - https://archive.ics.uci.edu/dataset/477/real+estate+valuation+data+set
1.2 Auto-mpg dataset – zmienną niezależną jest ***mpg*** https://www.kaggle.com/datasets/uciml/autompg-dataset

Przed przystąpienie do tworzenie modeli sprawdź czy dane nadają się do regresji liniowej, regresji wielokrotnej oraz regresji uwzględniającej interakcje pomiędzy czynnikami. W szczególności sprawdź:

a) Przydatność poszczególnych zmiennych niezależnych – Dane w plikach mogą zawierać kolumny, które nie nadają się do analizy modelem liniowym (np. nr id, dane kategoryczne). Wyklucz te dane.
b) Brak brakujących wartości – Kompletność danych jest kluczowym punktem przed rozpoczęciem analizy. W jaki sposób możemy zareagować na braki w pewnych wartościach?
c) Brak współliniowości zmiennych objaśniających – Zmienne objaśniające nie powinny być silnie skorelowane ze sobą. Jeśli współliniowość występuje, może to prowadzić do niestabilności estymacji parametrów. Zwizualizuj dane. Jakim testem możemy sprawdzić czy dane są skorelowane
d) Brak danych odstających – Dane odstające mogę negatywnie wpłynąć na działanie modeli liniowych (i nie tylko). Zwizualizuj dane. Jakie podejście możemy przyjąć w stosunku do zbioru z danymi odstającymi.

Dla każdego z tych zbiorów przeprowadź regresję wieloraką z uwzględnieniem interakcji pomiędzy czynnikami. Sprawdź które zmienne niezależne mają istotny wpływ na model. Po stworzeniu modelu sprawdź czy spełnione są założenia regresji. W szczególności:

I) Liniowość – Zakłada się, że istnieje liniowa zależność między zmienną objaśnianą (y) a zmiennymi objaśniającymi (X). Oznacza to, że model przyjmuje postać równania liniowego:
II) Brak autokorelacji reszt: Reszty nie powinny wykazywać wzorca ani być skorelowane. Jakim testem można to sprawdzić? Jak wywołać ten test w R?
III) Homoskedastyczność – Wariancja reszt powinna być stała dla wszystkich wartości zmiennych objaśniających. Jakim testem można to sprawdzić? Jak wywołać ten test w R?
IV) Normalność reszt – Reszty powinny mieć rozkład normalny o średniej równej zero.

Zadanie 2

Regresja Poissonowska:

2. Dane są atrybuty niezależne $X_1, \ldots, X_p$ oraz atrybut zależny Y, taki że $Y \in \mathbb{Z}_+$

Zakładamy, że zmienne objaśniane Y mają rozkład Poissona:

$$P(Y = k) = \frac{\lambda^k e^{-\lambda}}{k!},$$

gdzie λ jest parametrem tego rozkładu.

Zadanie 1. Podaj postać funkcji wiarygodności dla tego modelu regresji zakładając, że dysponujemy n przypadkami i dla każdego przykładu spełniona jest zależność

$$\log(\lambda) = a_0 + a_1 X_1 + \cdots + a_p X_p$$

2.1 Wczytaj dane z pliku *poisson.data.*

2.2 Zoptymalizuj funkcję wiarygodności (funkcja *optim*) dla tego modelu zakładając, że $p = 1$.

2.3 Odczytaj optymalne parametry.

2.4 Naucz na tych samych danych model przy pomocy wbudowanego moedlu

glm(model , data, family = poisson)

2.5 Wypisz podstawowe informacje dotyczące nauczonego modelu: *summary(model)*

2.6 Odpowiedz na pytania:

a) Czym są Deviance Residual i jakich wartości powinniśmy się spodziewać.

b) Które wartości modelu są istotne? Czy są to te same wartości co uzyskane funkcją *optim*?

c) Co oznaczają Null deviance i Residual deviance, i jak je interpretujemy?

Zadanie 3

3. Wczytaj dane ***ships*** z pakietu MASS: *data("ships")*

3.1 Przeczytaj odpis danych. Zwróć uwagę jakie wartości przyjmują kolejne atrybuty.

3.2 Przeprowadź regresją Poissonowską, gdzie zmienną objaśnianą jest ***incidents***. Które atrybuty należy włączyć do modelu.

3.3 W jaki sposób program potraktował kolejne zmienne?

3.4 Wykonaj wykres otrzymanych reszt (*resid(model, type = "deviance")*). Czy spełnione jest założenie o ich normalności?

Zadanie 4

4. Wczytaj dane **esoph** z pakietu ISwR: *data("esoph")*

4.1 Przeczytaj odpis danych.

4.2 Przeprowadź regresją Poissonowską, gdzie zmienną objaśnianą jest ***ncases***.

4.3 Które atrybuty są istotne dla modelu?

4.4 Stwórz model bazując jedynie na istotnych atrybutach. Czy parametry modelu się zmienił i dlaczego.

4.5 Oceń dopasowanie modelu (sprawdź warunki resyduów).

Zadanie 5

Regresja Porządkowa (CLM - Cumulative Link Model)

5. Wczytaj dane z pliku ***clm.data***

5.1 Przejrzyj dane i wybierz jedynie istotne atrybuty.

5.2. Przeprowadź na danych regresję porządkową CLM. Możesz skorzystać z pakietu ***ordinal***

install.packages("ordinal")

library(ordinal)

model <- clm(model, data = dane)

5.3 Przejrzyj wyświetlane wyniki. Co oznaczają poszczególne wartości?

Zadanie 6

6. Wczytaj dane ***wine*** z pakietu ***ordinal***: *data(wine, package = "ordinal")*

6.1 Przeprowadź regresję względem atrybutu rating.

6.2 Wykonaj przewidywania modelu na danych uczących

predict(model, wybrane_atrybuty, type = "prob")

6.3 Opisz w jaki sposób są wyświetlane wyniki.

6.4 Przekształć atrybut zależny tak, że wartości mniejsze niż 4 oznacz jako zero, a wartości większe bądź równe 4 jako 1.

6.5 Przeprowadź regresję porządkową na tak zakodowanych klasach i regresję logistyczną. Czy wyniki różnią się od siebie?

Sprawozdanie powinno zawierać:

1. Dane identyfikacyjne autora.
2. Tytuł zadania oraz tytuły rozwiązywanych zadań.
3. Wszystkie miary i statystyki wykorzystywane do oceny działania modelu powinny zostać jednokrotnie zdefiniowane w sprawozdaniu (z użyciem wzorów).
4. Proszę o wstawienie komend w R, otrzymanych wyników oraz opisu ich interpretacji. Komendy i wyniki mogą być wklejonymi print screen-ami.

Sprawozdania proszę przesłać w formie plików *pdf*.